

MOSS

Microservice-oriented Object Storage Service

A distributed object storage system in Java + gRPC — decoupling metadata coordination from physical byte storage.




Henrique Ferreira - 113600

Pedro Melo - 114208

O objetivo: separar coordenação de armazenamento

Os metadados (onde está) vivem separados dos bytes (a data). Assim o sistema escala horizontalmente — basta juntar nós de armazenamento, sem gargalo no coordenador.



O coordenador: políticas + decisão de Assign



Greedy assignment

escolhe o volume com mais espaço livre



Capacidade conservadora

assume só 90% do espaço reportado



Criação balanceada

novo volume no nó com menos volumes



Liveness · timeout 20 s

nós sem heartbeat são ignorados



Mínimo do cluster

Assign exige ≥ 2 volume nodes vivos



Ticket <vid>:<fid><cookie> cookie = nonce 32-bit (8 hex)

Fluxo de decisão do Assign



O disco: layout append-only + I/O concorrente

Layout em disco — 2 ficheiros por volume



→ ao arrancar, o nó relê cada entrada do .idx e reconstrói o índice em memória.

I/O concorrente por volume



Writers

ReentrantLock por volume

- append em .data (EOF)
- append entrada .idx
- atualiza índice + contadores




Readers

Sem lock (lock-free)

- index.get(fid) — ConcurrentHashMap
- channel.read(buf, pos)
- leitura posicional, sem ponteiro partilhado

Leituras nunca bloqueiam escritas.

Orquestração – o fluxo de Put



Ordem importa

Os bytes ficam duráveis no volume PRIMEIRO; só depois é que os metadados são gravados. Assim um Get nunca vê um objeto cujos bytes ainda não existem.

Get & List

Get: entry (read lock) → Lookup no Manager em tempo de leitura → Read no volume atual.

List

: filtra a map por prefixo bucket/ e devolve {path, size, timestamp}.

Estado partilhado → primitiva → garantia



synchronized é proibido. Toda a exclusão mútua usa apenas java.util.concurrent — locks, atomics e coleções concorrentes.

Nó	Estado partilhado	Primitiva	Garantia
Manager	registo de volumes, mapa URL, last-seen	ConcurrentHashMap x4	updates de heartbeat
Manager	ledger (fid/vid) + criação de volume	ReentrantLock + commit	IDs atómicos, sem reuso no restart
Volume	caminho de escrita (data + idx)	ReentrantLock /volume	1 escritor por volume → sem races
Volume	índice de ficheiros / contadores	ConcurrentHashMap · Atomic	leituras O(1) sem lock
Object	mapa de metadados	ReentrantReadWriteLock	muitas leituras, escrita exclusiva
Object	Puts em progresso	putIfAbsent (pendingPuts)	dedupe de Puts da mesma chave

Dois padrões-chave em ação



Double-checked locking

Manager — criar um volume no máximo uma vez, mesmo com vários Assign em corrida:

- 1 1ª rasteio sem lock (caminho rápido comum)
- 2 Nenhum serve? → adquire ledgerLock
- 3 Re-verifica dentro do lock
- 4 Só então aloca vid, persiste e chama AssignVolume




Lock só no disco local

O lock por volume é libertado ANTES das chamadas de rede às réplicas:

- | | | |
|----|---|---------------------------------------|
| t0 | █ | adquire lock do volume |
| t1 | █ | grava data + idx, atualiza índice |
| t2 | █ | liberta lock ◀ só o disco local |
| t3 | █ | encaminha Write → réplica 1 |
| t4 | █ | encaminha Write → réplica 2 |
| t5 | █ | OK só se TODAS confirmarem (síncrono) |

Replicação síncrona, opcional por objeto

Opt-in via `./run moss put -R n ...` (n cópias extra → n+1 no total)



Assign (Manager)

escolhe n nós distintos e cria o mesmo vid em cada; conjunto parcial é rejeitado.



Write (Volume)

o primário grava e reencaminha; só responde OK quando todas confirmam.



Read failover

a lista de URLs é primário-primeiro; se cair, o Lookup devolve uma réplica viva.

Todos os requisitos obrigatórios + replicação

- ✓ Manager — Assign · Lookup · Heartbeat · State
- ✓ Volume — AssignVolume · Write · Read + recovery
- ✓ Object — Put · Get · List + persistência
- ✓ CLI — put · get · list
- ✓ GUI de monitorização (Swing)
- ✓ Persistência (MVStore + replay do .idx)
- ✓ Replicação síncrona por objeto (extra)
- ✗ Object deletion — tombstones + compact (não feito)

Limites do sistema

Tamanho máx. ficheiro	4 MiB
Capacidade do volume	32 MiB
Volumes por nó	5 (160 MiB)
Intervalo de heartbeat	5 s
Timeout de liveness	20 s
Fator conservador	0.9
Mínimo de volume nodes	2